

测速线表面流速重建模型 V1 最终报告

物理正则版 vs 纯净基线 (RoPE + 纯 L2) 对照评测

2026-09-21 · 数据 218,306 断面 (221 站) · 站级分层划分 · 测试集 40 站 / 182.4 万条测速线 · 日志
runs/v1/journal.md

摘要

- 单一变量对照**: 两版模型同架构 (82.76M)、同数据 (218,306 断面)、同站级分层划分, 仅两处不同——物理版的形态偏置注意力 + MSE+五项物理正则, 对照版的 RoPE 位置编码 + 纯 L2。
- 总体**: 纯净版全面占优——RMSE 0.342 对 0.364 (好 6.0%), NSE 0.835 对 0.814, bias 0.023 对 0.056; 对原始观测中位数基线的 skill 0.553 对 0.524。
- 误差结构**: 物理版的回归趋中被证实并部分归因于物理正则——纯净版在低速段 [0.2,0.5) 的 bias 从 +0.164 降至 +0.073, 高速段 (≥ 2 m/s) 严重低估占比从 18.4% 降至 15.3%, 剧烈分歧 (|误差| > 0.5 m/s) 占比从 8.7% 降至 6.6%。
- 物理先验的守护价值**: 在观测薄弱的场景物理版反而更稳——零速枯水线 RMSE 0.199 对 0.252、光流-only 测次 RMSE 0.281 对 0.471。物理项充当了「观测不可信时的兜底先验」。
- 共同短板**: 两版的最优验证 epoch 都停在早期 (ep26 / ep19) 后进入长平台, 且高速段 (≥ 3 m/s) RMSE 均在 0.85+——高速与观测-目标矛盾样本是下一阶段的重点。

一、任务与数据

模型从原始分段流速观测 (STIV 30 秒视频段 / 光流区域估计) 重建断面各测速线表面流速。数据池 **218,306 条质检通过断面** (221 站 / 254 设备, 2024-09 – 2026-08 为主, reliability=1)。每断面测速线中位 35 条, 每线原始观测中位 10 个。

划分采用**站级分层** (按站点均速分位切 10 层、层内 70/15/15), 站间不相交。修正动因: 随机站划分曾把偏快河段集中分入测试集 (流速中位 0.737 对训练 0.429), 分层后测试集中位回到 0.441。全库 25% 分位流速恰为 0, 诊断为「枯水线」(98–100% 水深 < 1 cm) 的真实物理规律, 训练全部保留。

二、两版设定 (单一变量对照)

项	物理版 (runs/v1)	纯净版 (runs/v1_mse)
注意力	形态偏置 (线距/水深/岸别/坡度四个可学习 β)	vanilla attention + RoPE 位置编码 (q/k 按绝对位置旋转)
损失	全断面 MSE + 五项物理正则 ($\lambda=0.05/0.02/0.01/0.02/0.01$)	纯 L2 (mse_only)

其余	同架构 82.76M (768/12/14/2304)、同分层划分、AdamW lr 5e-5、batch 32、100 epoch 预算、dropout 0、seed 42	同左
实际停止	ep70 闸门触发 (best 停在 ep26, 44 epoch 无新最优), 存档 attempt5_ep70gate	ep87 用户叫停 (best 停在 ep19), 检查点已留存
训练时长	约 9.5 h (490 s/epoch)	约 8 h (351 s/epoch)

三、总体结果

检查点取验证 RMSE 最优的 ep26 (物理版) / ep19 (纯净版)。站级测试集 (40 站、182.4 万条测速线, 训练全程未见) 总体: **物理版 RMSE 0.364 / NSE 0.814 / bias +0.056; 纯净版 RMSE 0.342 / NSE 0.835 / bias +0.023。**




图1 物理版重建流速 vs 目标流速密度图 (测试集全量 182 万线, 对数色标)。低速段散布在对角线上方 (正偏置), 高速段被压向均值。




图2 纯净版同口径密度图。主对角带更紧密，[0.2,0.5) 段抬升效应明显减弱；虚线y=x，灰带±0.3 m/s。

指标	物理版	纯净版	原始中位数基线
RMSE (m/s)	0.364	0.342	0.764
MAE (m/s)	0.176	0.159	0.266
NSE	0.814	0.835	0.178
bias (m/s)	+0.056	+0.023	+0.020
skill vs 中位数基线	0.524	0.553	—

两版都把「直接取原始观测中位数」的误差砍掉一半以上。纯净版总体 RMSE 再比物理版低 6.0%，且 bias 减半——去掉了物理正则对零速/低速的抬升效应后，整体预测更贴近目标。

四、误差结构：分速度段拆解

目标速度段	RMSE 物理 / 纯净	bias 物理 / 纯净	线数	占优方
[0, 0.2)	0.397 / 0.351	+0.132 / +0.112	318k	纯净
[0.2, 0.5)	0.304 / 0.223	+0.164 / +0.073	330k	纯净（大幅）
[0.5, 1)	0.204 / 0.205	+0.067 / +0.011	334k	纯净（bias）
[1, 2)	0.308 / 0.331	-0.060 / -0.089	313k	物理
[2, 3)	0.510 / 0.505	-0.208 / -0.164	107k	纯净（bias）
[3+)	0.849 / 0.885	-0.360 / -0.228	22k	物理

用户此前的诊断「实测 0 处预测偏大、实测大处预测偏小」在物理版上完全成立，且主要元凶是物理正则：纯净版把 [0.2,0.5) 段的正偏置砍掉一半以上，高速段严重低估占比从 18.4% 降至 15.3%。但物理项并非一无是处——它把纯零速线的 RMSE 压到 0.199（纯净版 0.252，零速线平均

预测 0.027 对 0.048)，并显著改善光流-only 测次（0.281 对 0.471）。

五、跨站 / 跨设备 / 分源泛化




图3 物理版各测试站 RMSE (左, 红=RMSE>0.8) 与 NSE (右, 灰=近常数站指标退化, †标记)。两版跨站分布形态相似; 纯净版中位 RMSE 0.263 更好, 但 p90 0.677 更差。

站级中位: 物理版 RMSE 0.289 / NSE 0.744; 纯净版 RMSE 0.263 / NSE 0.637。纯净版中位 RMSE 更好但 NSE 中位反而更低, 且 p90 (0.677 对 0.464) 更差——它的误差分布更两极: 多数站更好, 少数站 (观测薄弱型) 更差。最差站两版一致: 站 00423 (RMSE 1.14 / 1.17) 与站 00156 (0.98 / 1.03), 后者即「原始观测 8+ m/s、目标 0.1」的观测-目标矛盾站 (原始 STIV 超出河流物理上限, 详见 journal)。

分源是两版最大的分野: 光流-only 测次物理版 RMSE 0.281 / NSE 0.846, 纯净版 0.471 / 0.567。解释: 物理版的形态偏置注意力把「水深、岸别、坡度」的结构先验直接注入注意力, 在原始观测稀疏 (光流-only 每线常只有 1 个估计) 时兜底; 纯净版只能依赖 RoPE 与嵌入里的形态通道, 观测一弱就漂。STIV 测次 (占 98.9%) 纯净版反而更好 (0.341 对 0.364)。

5.1 观测-目标矛盾的普遍性检验 (最终模型复核)

对站 00156 的「原始观测 8+ m/s 对目标 0.1 m/s」现象做了全测试集复核。**矛盾普遍存在但低发, 个别站集中:** 全测试集 182 万条有观测的线中, 观测远大于目标 (差值 $> \max(0.5, 1.5 \times \text{目标})$) 的占 5.4% (矛盾线上观测中位 2.21 m/s 对目标中位 0.21, 约 10 倍), 观测远小于目标的占 4.6%, 合计约 10%; 其余 90% 的线观测与目标基本一致 (相关系数 $r=0.722$)。分站看, 矛盾率中位仅 5.9%, 只有 2/37 个站的矛盾率超过 20% (站 00156 为最严重, 全库 1,727 个断面、原始观测段均值中位 0.25 m/s 对目标 0.09 m/s, 最差断面单线达 8.7 m/s)。

用最终两版检查点复核该站: 物理版 1,727 断面 / 63,899 线上 RMSE 1.020 (预测均值 0.75 对目标

0.158)，纯净版 RMSE 0.791（预测均值 0.47）——两版都部分跟随了被高估的原始观测，但纯净版跟随程度更低。

对模型可靠性的含义：在 90% 观测-目标一致的线上，两版都可靠（RMSE：物理版 0.270、纯净版 0.244）；矛盾线上误差升至 0.80–0.82（约 3 倍），且两版在矛盾方向的追随权重都很低（0.05–0.18），说明模型总体保守、并未普遍盲从观测。因此「监测质量不是完全垃圾即产出可靠结果」成立；对约 10% 的矛盾线（其中 2 个集中站贡献最大），以「原始观测与目标剧烈分歧」为特征即可自动筛出送人工复核——该规则无需模型参与，一行判据即可上线。

六、断面重建案例








图4 物理版：最好 / 中位 / 最差（观测-目标矛盾） / 枯水 / 光流-only 五类断面。枯水区预测=0，「没水→流速0」规律已学会。








图5 纯净版：同五类断面。低速段跟随更紧，但枯水区偶有0.1–0.2 m/s 的虚增速（物理版没有）。




图6 物理版损失与验证 RMSE 曲线 (ep70 停止时止)。最优停在 ep26，其后 44 epoch 平台。




图7 纯净版损失与验证 RMSE 曲线 (ep87 停止时止)。最优停在 ep19，但整体水平低于物理版。

七、结论

结论 1（损失函数）：物理正则回归中的直接成因之一。纯净版总体 RMSE 好 6%、bias 减半、剧烈分歧率从 8.7% 降到 6.6%——纯 L2 让模型对「该 0 就 0、该大就大」的响应更忠实。

结论 2（物理先验的两面性）：物理正则观测充足时是拖累（把预测拉向均值），在观测薄弱时是兜底（枯水线、光流-only 显著更稳）。它不是该不该要的问题，而是该在哪起作用的问题——作为无条件附加损失是错的，作为「观测置信度低时加大的自适应先验」可能是对的。

结论 3（共同瓶颈）：两版最优验证 epoch 都停在早期 (ep26/ep19) 后进入长平台，且 [3+] 高速段 RMSE 均在 0.85+。瓶颈不在训练时长，而在高速样本稀少（占比 1.2%）与观测-目标矛盾样本。建议下一阶段：高速段过采样 / 分段损失加权 + 剧烈分歧集合人工复核。

结论 4（交付建议）：以纯净版为主模型（总体与分歧率全面占优、结构干净无手工先验）；对光流-only 与疑似枯水断面叠加物理版或物理先验做二段校验；两版分歧集合（合计约 6–9% 线）进入人工复核队列。

附录 A 评测口径

测试集为 40 个训练全程未见的站、45,118 断面、1,824,298 条测速线。基线为逐线原始观测中位数

(raw_median) 与截断均值 (raw_clip_mean)，均不含置信度信息，与模型输入口径一致。零速线指目标恰为 0 的线（枯水物理）；高速线指目标 ≥ 2 m/s；剧烈分歧指 $|\text{预测}-\text{目标}| > 0.5$ m/s。目标 std < 0.1 m/s 的近常数站 NSE 退化，只报 RMSE。

报告与全部中间产物见 runs/v1/ 与 runs/v1_mse/: journal.md（完整决策与事故日志）、history.json（逐 epoch 指标）、comparison.json（对比明细）、metrics_test_*.json（含基线）、gen_*_final.json（泛化明细）、report_figs/（图件）。