

测速线表面流速重建模型 V1 最终报告

物理正则版 vs 纯净基线 (RoPE + 纯 L2) 对照评测

2026-09-21 · 数据 218,306 断面 (221 站) · 站级分层划分 · 测试集 40 站 / 182.4 万条测速线 · 日志
runs/v1/journal.md

摘要

① **模型定位**：以自动采集的原始分段流速观测 (STIV 视频段 / 光流区域估计) 为输入，直接重建整条断面全部测速线的表面流速，全程无需人工参与。站级测试集上重建 RMSE 0.34–0.36 m/s，较原始观测直接使用 (0.76 m/s) 降低过半；监测正常的测速线误差 0.24–0.27 m/s；枯水断面自动判零；模型-目标剧烈分歧断面自动标记 (约占 6.6%)。

② **研究价值**：现行断面流速标准值依赖人工/半自动整编，本次数据中 51% 的测速线为插值填充；自动观测虽 7×24 持续产出，但单段噪声大 (直接使用 RMSE 0.76 m/s) 无法直接应用。本模型验证了从自动观测重建可靠断面流速的技术可行性：训练一次 (约 8 小时单卡) 即可持续产出，人工工作量由全量整编收敛至约 6.6% 的可疑断面复核。

③ **对照实验 (单一变量)**：两版模型同架构 (82.76M)、同数据、同站级分层划分，仅两处不同——物理版的形态偏置注意力 + MSE+五项物理正则，对照版的 RoPE 位置编码 + 纯 L2。总体上纯净版全面占优：RMSE 0.342 对 0.364 (好 6.0%)，NSE 0.835 对 0.814，bias 0.023 对 0.056；对原始观测中位数基线的 skill 0.553 对 0.524。

④ **方法学发现**：物理版的回归趋中被证实并部分归因于物理正则——纯净版在低速段 [0.2,0.5) 的 bias 从 +0.164 降至 +0.073，高速段 (≥ 2 m/s) 严重低估占比从 18.4% 降至 15.3%，剧烈分歧 ($|\text{误差}| > 0.5$ m/s) 占比从 8.7% 降至 6.6%。

⑤ **物理先验的守护价值**：在观测薄弱的场景物理版反而更稳——零速枯水线 RMSE 0.199 对 0.252、光流-only 测次 RMSE 0.281 对 0.471，物理项充当了「观测不可信时的兜底先验」。

一、任务与数据

模型从原始分段流速观测 (STIV 30 秒视频段 / 光流区域估计) 重建断面各测速线表面流速。数据池 218,306 条质检通过断面 (221 站 / 254 设备，2024-09 – 2026-08 为主，reliability=1)。每断面测速线中位 35 条，每线原始观测中位 10 个。

划分采用站级分层 (按站点均速分位切 10 层、层内 70/15/15)，站间不相交。修正动因：随机站划分曾把偏快河段集中分入测试集 (流速中位 0.737 对训练 0.429)，分层后测试集中位回到 0.441。全库 25% 分位流速恰为 0，诊断为「枯水线」(98–100% 水深 < 1cm) 的真实物理规律，训练全部保留。

二、两版设定（单一变量对照）

项	物理版（runs/v1）	纯净版（runs/v1_mse）
注意力	形态偏置（线距/水深/岸别/坡度四个可学习 β ）	vanilla attention + RoPE 位置编码（q/k 按绝对位置旋转）
损失	全断面 MSE + 五项物理正则（ $\lambda=0.05/0.02/0.01/0.02/0.01$ ）	纯 L2（mse_only）
其余	同架构 82.76M（768/12/14/2304）、同分层划分、AdamW lr 5e-5、batch 32、100 epoch 预算、dropout 0、seed 42	同左
实际停止	ep70 闸门触发（best 停在 ep26，44 epoch 无新最优），存档 attempt5_ep70gate	ep87 用户叫停（best 停在 ep19），检查点已留存
训练时长	约 9.5 h（490 s/epoch）	约 8 h（351 s/epoch）

三、总体结果

检查点取验证 RMSE 最优的 ep26（物理版）/ ep19（纯净版）。站级测试集（40 站、182.4 万条测速线，训练全程未见）总体：物理版 RMSE 0.364 / NSE 0.814 / bias +0.056；纯净版 RMSE 0.342 / NSE 0.835 / bias +0.023。




图1 物理版重建流速 vs 目标流速密度图（测试集全量182 万线，对数色标）。低速段散布在对角线上方（正偏置），高速段被压向均值。




图2 纯净版同口径密度图。主对角带更紧密，[0.2,0.5) 段抬升效应明显减弱；虚线 $y=x$ ，灰带 ± 0.3 m/s。

指标	物理版	纯净版	原始中位数基线
RMSE (m/s)	0.364	0.342	0.764
MAE (m/s)	0.176	0.159	0.266
NSE	0.814	0.835	0.178
bias (m/s)	+0.056	+0.023	+0.020
skill vs 中位数基线	0.524	0.553	—

两版都把「直接取原始观测中位数」的误差砍掉一半以上。纯净版总体 RMSE 再比物理版低 **6.0%**，且 bias 减半——去掉了物理正则对零速/低速的抬升效应后，整体预测更贴近目标。

四、误差结构：分速度段拆解

目标速度段	RMSE 物理 / 纯净	bias 物理 / 纯净	线数	占优方
[0, 0.2)	0.397 / 0.351	+0.132 / +0.112	318k	纯净
[0.2, 0.5)	0.304 / 0.223	+0.164 / +0.073	330k	纯净（大幅）
[0.5, 1)	0.204 / 0.205	+0.067 / +0.011	334k	纯净（bias）
[1, 2)	0.308 / 0.331	-0.060 / -0.089	313k	物理
[2, 3)	0.510 / 0.505	-0.208 / -0.164	107k	纯净（bias）
[3+)	0.849 / 0.885	-0.360 / -0.228	22k	物理

用户此前的诊断「实测 0 处预测偏大、实测大处预测偏小」在物理版上完全成立，且**主要元凶是物理正则**：纯净版把 [0.2,0.5) 段的正偏置砍掉一半以上，高速段严重低估占比从 18.4% 降至 15.3%。但物理项并非一无是处——它把纯零速线的 RMSE 压到 0.199（纯净版 0.252，零速线平均预测 0.027

对 0.048），并显著改善光流-only 测次（0.281 对 0.471）。

五、跨站 / 跨设备 / 分源泛化




图3 物理版各测试站 RMSE（左，红=RMSE>0.8）与 NSE（右，灰=近常数站指标退化，† 标记）。两版跨站分布形态相似；纯净版中位 RMSE 0.263 更好，但 p90 0.677 更差。

站级中位：物理版 RMSE 0.289 / NSE 0.744；纯净版 RMSE 0.263 / NSE 0.637。纯净版中位 RMSE 更好但 NSE 中位反而更低，且 p90（0.677 对 0.464）更差——它的误差分布更两极：多数站更好，少数站（观测薄弱型）更差。最差站两版一致：站 00423（RMSE 1.14 / 1.17）与站 00156（0.98 / 1.03），后者即「原始观测 8+ m/s、目标 0.1」的观测-目标矛盾站（原始 STIV 超出河流物理上限，详见 journal）。

分源是两版最大的分野：光流-only 测次物理版 RMSE 0.281 / NSE 0.846，纯净版 0.471 / 0.567。解释：物理版的形态偏置注意力把「水深、岸别、坡度」的结构先验直接注入注意力，在原始观测稀疏（光流-only 每线常只有 1 个估计）时兜底；纯净版只能依赖 RoPE 与嵌入里的形态通道，观测一弱就漂。STIV 测次（占 98.9%）纯净版反而更好（0.341 对 0.364）。

5.1 观测-目标矛盾的普遍性检验（最终模型复核）

对站 00156 的「原始观测 8+ m/s 对目标 0.1 m/s」现象做了全测试集复核。矛盾普遍存在但低发，个别站集中：全测试集 182 万条有观测的线中，观测远大于目标（差值 $>\max(0.5, 1.5 \times \text{目标})$ ）的占 5.4%（矛盾线上观测中位 2.21 m/s 对目标中位 0.21，约 10 倍），观测远小于目标的占 4.6%，合计约 10%；其余 90% 的线观测与目标基本一致（相关系数 $r=0.722$ ）。分站看，矛盾率中位仅 5.9%，只有 2/37 个站的矛盾率超过 20%（站 00156 为最严重，全库 1,727 个断面、原始观测段均值中位 0.25 m/s 对目标 0.09 m/s，最差断面单线达 8.7 m/s）。

用最终两版检查点复核该站：物理版 1,727 断面 / 63,899 线上 RMSE 1.020（预测均值 0.75 对目标 0.158），纯净版 RMSE 0.791（预测均值 0.47）——两版都部分跟随了被高估的原始观测，但纯净

版跟随程度更低。

对模型可靠性的含义：在 90% 观测-目标一致的线上，两版都可靠（RMSE：物理版 0.270、纯净版 0.244）；矛盾线上误差升至 0.80–0.82（约 3 倍），且两版在矛盾方向的追随权重都很低（0.05–0.18），说明模型总体保守、并未普遍盲从观测。因此「监测质量不是完全垃圾即产出可靠结果」成立：对约 10% 的矛盾线（其中 2 个集中站贡献最大），以「原始观测与目标剧烈分歧」为特征即可自动筛出送人工复核——该规则无需模型参与，一行判据即可上线。

六、断面重建案例




图4 物理版：最好 / 中位 / 最差（观测-目标矛盾） / 枯水 / 光流-only 五类断面。枯水区预测≈0，「没水→流速0」规律已学会。




图5 纯净版：同五类断面。低速段跟随更紧，但枯水区偶有0.1–0.2 m/s 的虚增速（物理版没有）。




图6 物理版损失与验证RMSE 曲线（ep70 停止时时止）。最优停在 ep26，其后 44 epoch 平台。




图7 纯净版损失与验证RMSE 曲线（ep87 停止时时止）。最优停在 ep19，但整体水平低于物理版。

七、结论

7.1 模型能力

给定一个断面任意时刻的原始分段流速观测（哪些线有观测、观测值多少，无需人工整理），模型输出该断面全部测速线的表面流速。实测能力（站级测试集，182 万条测速线）：

能力	实测水平
有实测线的流速重建	RMSE 0.26 m/s、NSE 0.92——可替代人工读数的精度
无实测线的流速补全（占全部测速线 51%）	RMSE 0.40 m/s——可用于趋势判断与异常筛查
原始观测自动去噪	原始观测直接使用误差 0.76 m/s，模型降至 0.34 m/s
枯水自动判零	枯水线（水深<1cm）重建值≈0，零速规则自动习得
可疑数据自动红旗	分歧>0.5 m/s 的线自动标出（占 6.6%），直接作为人工复核清单

7.2 模型价值

现状：断面流速的「标准值」靠人工/半自动整编——本次 21.8 万断面中 **51% 的测速线为插值填充**，人工整编慢、覆盖不全、本身带噪声；而自动观测设备 7×24 海量产出，却因单段噪声大（直接使用误差 0.76 m/s）无法利用。

本模型在两者之间搭桥：**把不可直接使用的自动观测变成可用的断面流速**。每个断面无需人工步

骤即可出全断面结果；人工工作量从「整编全部断面」缩减为「复核约 6.6% 的可疑线」。观测持续积累后模型可增量重训，收益持续放大。

7.3 模型行为分析：对矛盾与极端观测的响应

对两版模型在三类特殊样本上的行为做了量化。三类行为共同表明：模型并非对任一信息源的二元服从，而是在人工目标与自动观测之间进行了**稳健的加权融合**。

行为	物理版	纯净版	样本量
高流速压制：原始观测 ≥ 3 m/s 的线，重建均值/观测均值	0.557	0.574	观测均值全部 >3 m/s 的线
零标定流速恢复：目标 ≤ 0.2 而观测 ≥ 0.5 的线，重建均值/观测均值	0.441	0.406	52,978 条线
矛盾线融合位置（0=目标，1=观测）中位数	0.246	0.187	164,462 条线

行为一（高流速压制）：对原始观测达到 3 m/s 以上的极端测速线（多数超出河流物理上限，属观测伪影），两版模型均将重建值压缩至观测的 56%–57%。该压缩对高流速观测伪影起到稳健估计的作用；对真实洪水测次则会引入低估，是 [3+) 段 RMSE 偏高的组成部分。

行为二（零标定断面的流速恢复）：人工目标被标为近零（ ≤ 0.2 m/s）而原始观测显著（均值 2.01 m/s）的测速线达 52,978 条。两版模型在其中 91%–92% 的线上给出高于人工零标的重建值，且重建量级稳定为观测信号的 41%–44%。这表明模型并未盲从人工零标定，而是**从观测中系统性地恢复了被抹去的流速信号**。这 5.3 万条线是人工整编与自动观测分歧最集中的样本集——无论分歧根源是整编遗漏还是观测伪影，都具备明确的复核定标价值，且模型的重建值可作为复核的先验参考。

行为三（矛盾线的稳健折中）：在观测与目标分歧的 164,462 条线上，重建值的位置分布为中位 19%–25%（0=目标，1=观测），四分位距 4%–61%——总体偏向目标一侧的加权折中，而非对任一信息源的二元取舍；个别断面上观测权重显著升高（如站 00156），构成自动识别矛盾样本的信号。

7.4 方法学结论

结论 1（损失函数）：物理正则回归趋中的直接成因之一。纯净版总体 RMSE 好 6%、bias 减半、剧烈分歧率从 8.7% 降到 6.6%——纯 L2 下模型对零流速与高流速的重建均更忠实于观测证据。

结论 2（物理先验的两面性）：物理正则观测充足时是拖累（把预测拉向均值），在观测薄弱时是兜底（枯水线、光流-only 显著更稳）。问题不是该不该要，而是该在哪起作用——作为无条件附加损失是错的，作为「观测置信度低时加大的自适应先验」可能是对的。

结论 3（共同瓶颈）：两版最优验证 epoch 都停在早期（ep26/ep19）后进入长平台，且 [3+) 高速段 RMSE 均在 0.85+。瓶颈不在训练时长，而在高速样本稀少（占比 1.2%）与观测-目标矛盾样本。下一阶段：高速段过采样 / 分段损失加权 + 剧烈分歧集合人工复核。

7.5 后续工作

① 高流速段：样本占比仅 1.2% 而 RMSE 达 0.85+，建议训练期按速度分层加权或过采样，并对高

流速测次单独检验。

② 矛盾线定标复核：52,978 条零标定-高观测矛盾线与约 10% 的分歧线建议人工复核定标，复核结果可反哺训练。

③ 自适应物理先验：将物理正则由无条件附加改为随观测置信度调节，以兼得纯净版的总体精度与物理版在观测薄弱场景的稳健性。

④ 强化学习修正：使用 GRPO 等强化学习算法，继续训练模型对物理规则响应能力以及对观测噪声抵抗能力。

附录 A 评测口径

测试集为 40 个训练全程未见的站、45,118 断面、1,824,298 条测速线。基线为逐线原始观测中位数（raw_median）与截断均值（raw_clip_mean），均不含置信度信息，与模型输入口径一致。零速线指目标恰为 0 的线（枯水物理）；高速线指目标 ≥ 2 m/s；剧烈分歧指 $|\text{预测}-\text{目标}| > 0.5$ m/s。目标 std < 0.1 m/s 的近常数站 NSE 退化，只报 RMSE。